



TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH

Ho Chi Minh City University of Technology and Engineering



Improving the Reliability of AI-Based Lane Perception for Resource-Constrained Embedded Systems

Giáo viên hướng dẫn : Ths. Huỳnh Hoàng Hà

Sinh viên: Phạm Nguyễn Duy Phương

Võ Như Quyết

Mã số sinh viên: 22161068

22161072

Nghành học: Công nghệ kỹ thuật

điện tử - viễn thông

Lớp: 22161FIE1

Năm học: 2022-2026

Giới thiệu

Improving gồm **tăng độ tin cậy, độ chính xác, giảm độ trễ, bộ nhớ, ...**

AI-Based Lane Perception chuyên **nhận diện vạch làn, vùng có thể di chuyển, làn xe hiện tại, phương tiện/vật cản xung quanh, ...**

Resource-Constrained Embedded Systems hướng **đến các board nhúng phổ biến, chi phí thấp.**

Tiêu chí cần đặt ra ?

Lane Line, Drivable Area, Ego-Lane → các bài toán nhận thức làn đường bằng hình ảnh

Resource-Constrained Embedded Devices ?

- + Nhẹ (lightweight), chi phí thấp
- + **Memory efficient**
- + Công suất và năng lượng hạn chế

Làm nổi bật hướng đi

- + Reliable - lane không có vạch, mờ, thiếu, ...
- + **Low latency** - phù hợp xử lý gần thời gian thực
- + Tối ưu tài nguyên

Các bài báo nền tảng(1)



Phát hiện Lane



Chi phí cao



Độ chính xác cao



Yêu cầu thiết bị

Vấn đề giải quyết

Lane bị che khuất

Lane đứt đoạn

Ánh sáng yếu, chói sáng, thời tiết xấu


Output thực tế

Hỗ trợ xe nhận biết làn

Dẫn hướng

Driving-assistance systems

Mô hình SCNN đã giành giải nhất tại cuộc thi TuSimple Benchmark Lane Detection Challenge với độ chính xác đạt 96,53%.



Spatial as deep: Spatial cnn for traffic scene understanding

[X Pan](#), [J Shi](#), [P Luo](#), [X Wang](#), [X Tang](#)

Proceedings of the AAAI conference on artificial intelligence, 2018 • [ojs.aaai.org](#)

Abstract


Convolutional neural networks (CNNs) are usually built by stacking convolutional operations layer-by-layer. Although CNN has shown strong capability to extract semantics from raw pixels, its capacity to capture spatial relationships of pixels across rows and columns of an image is not fully explored. These relationships are important to learn semantic objects with strong shape priors but weak appearance coherences, such as traffic lanes, which are often occluded or not even painted on the road surface as shown in Fig. 1 (a). In this paper, we propose Spatial CNN (SCNN), which generalizes traditional deep layer-by-layer convolutions to slice-by-slice convolutions within feature maps, thus enabling message passings between pixels across rows and columns in a layer. Such SCNN is particular suitable for long continuous shape structure or large objects, with strong spatial relationship but less appearance clues, such as traffic lanes, poles, and wall. We apply SCNN on a newly released very challenging traffic lane detection dataset and Cityscape dataset. The results show that SCNN could learn the spatial relationship for structure output and significantly improves the performance. We show that SCNN outperforms the recurrent neural network (RNN) based ReNet and MRF+ CNN (MRFNet) in the lane detection dataset by 8.7% and 4.6% respectively. Moreover, our SCNN won the 1st place on the TuSimple Benchmark Lane Detection Challenge, with an accuracy of 96.53%.

[ojs.aaai.org](#)

ĂN BÓT ^

☆ Lưu 📄 Trích dẫn Trích dẫn 1642 bài viết Bài viết có liên quan Tất cả 9 phiên bản 🔗

Các bài báo nền tảng(1)



Spatial CNN (SCNN); mô hình này mở rộng phương pháp tích chập theo lớp truyền thống thành **tích chập theo từng lát cắt** (slice-by-slice) ngay trong các bản đồ đặc trưng (feature maps), qua đó cho phép **truyền tải thông tin giữa các điểm ảnh dọc theo hàng và cột trong cùng một lớp**. SCNN đặc biệt phù hợp với các đối tượng lớn hoặc có cấu trúc hình dạng dài và liên tục.

Spatial as deep: Spatial cnn for traffic scene understanding

X Pan, J Shi, P Luo, X Wang, X Tang

Proceedings of the AAAI conference on artificial intelligence, 2018 - ojs.aaai.org

Abstract

Convolutional neural networks (CNNs) are usually built by stacking convolutional operations layer-by-layer. Although CNN has shown strong capability to extract semantics from raw pixels, its capacity to capture spatial relationships of pixels across rows and columns of an image is not fully explored. These relationships are important to learn semantic objects with strong shape priors but weak appearance coherences, such as traffic lanes, which are often occluded or not even painted on the road surface as shown in Fig. 1 (a). In this paper, we propose Spatial CNN (SCNN), which generalizes traditional deep layer-by-layer convolutions to slice-by-slice convolutions within feature maps, thus enabling message passings between pixels across rows and columns in a layer. Such SCNN is particular suitable for long continuous shape structure or large objects, with strong spatial relationship but less appearance clues, such as traffic lanes, poles, and wall. We apply SCNN on a newly released very challenging traffic lane detection dataset and Cityscape dataset. The results show that SCNN could learn the spatial relationship for structure output and significantly improves the performance. We show that SCNN outperforms the recurrent neural network (RNN) based ReNet and MRF+ CNN (MRFNet) in the lane detection dataset by 8.7% and 4.6% respectively. Moreover, our SCNN won the 1st place on the TuSimple Benchmark Lane Detection Challenge, with an accuracy of 96.53%.

ojs.aaai.org

ẤN BỐT ^

☆ Lưu Trích dẫn Trích dẫn 1642 bài viết Bài viết có liên quan Tất cả 9 phiên bản

Các bài báo nền tảng(2)



Thông tin Lane



Hệ thống phức tạp



Thông tin phương tiện



Yêu cầu thiết bị

Vấn đề giải quyết (thời điểm đó có hai hướng)

+ Mediated Perception (nhận thức gián tiếp)

Camera xử lý phát hiện: + lane

+ biển báo

+ đèn giao thông

+ phương tiện,....

Vấn đề: quá nhiều thông tin, hệ thống phức tạp và tốn chi phí. cần laser range finder, GPS, radar và bản đồ chính xác.

+ Behavior Reflex (behavior reflex)

Camera → AI → Góc lái

Vấn đề: steering có thể trở nên mơ hồ (có xe phía trước theo, vượt trái hoặc vượt phải)

Output thực tế

Chuyển thông tin perception thành các driving affordances để controller quyết định lái xe.

Deepdriving: Learning affordance for direct perception in autonomous driving

C Chen, A Seff, A Kornhauser, J Xiao

Proceedings of the IEEE international conference on computer vision, 2015 • cv-foundation.org

Abstract

Today, there are two major paradigms for vision-based autonomous driving systems: mediated perception approaches that parse an entire scene to make a driving decision, and behavior reflex approaches that directly map an input image to a driving action by a regressor. In this paper, we propose a third paradigm: a direct perception approach to estimate the affordance for driving. We propose to map an input image to a small number of key perception indicators that directly relate to the affordance of a road/traffic state for driving. Our representation provides a set of compact yet complete descriptions of the scene to enable a simple controller to drive autonomously. Falling in between the two extremes of mediated perception and behavior reflex, we argue that our direct perception representation provides the right level of abstraction. To demonstrate this, we train a deep Convolutional Neural Network using recording from 12 hours of human driving in a video game and show that our model can work well to drive a car in a very diverse set of virtual environments. We also train a model for car distance estimation on the KITTI dataset. Results show that our direct perception approach can generalize well to real driving images. Source code and data are available on our project website.

cv-foundation.org

ẨN BỐT ^

☆ Lưu 77 Trích dẫn Trích dẫn 2797 bài viết Bài viết có liên quan Tất cả 22 phiên bản »



HCM-UTE

Các bài báo nền tảng(2)



AI xử lý thông tin : **góc** của xe so với hướng đường

khoảng cách từ xe đến lane markings

khoảng cách đến xe phía trước

khoảng cách đến xe trong lane hiện tại và lane bên cạnh.

=> xe lịch trái, phải nhiều , khoảng cách xe phía trước, tình trạng lane bên cạnh.

Deepdriving: Learning affordance for direct perception in autonomous driving

C Chen, A Seff, A Kornhauser, J Xiao

Proceedings of the IEEE international conference on computer vision, 2015 • cv-foundation.org


Abstract

Today, there are two major paradigms for vision-based autonomous driving systems: mediated perception approaches that parse an entire scene to make a driving decision, and behavior reflex approaches that directly map an input image to a driving action by a regressor. In this paper, we propose a third paradigm: a direct perception approach to estimate the affordance for driving. We propose to map an input image to a small number of key perception indicators that directly relate to the affordance of a road/traffic state for driving. Our representation provides a set of compact yet complete descriptions of the scene to enable a simple controller to drive autonomously. Falling in between the two extremes of mediated perception and behavior reflex, we argue that our direct perception representation provides the right level of abstraction. To demonstrate this, we train a deep Convolutional Neural Network using recording from 12 hours of human driving in a video game and show that our model can work well to drive a car in a very diverse set of virtual environments. We also train a model for car distance estimation on the KITTI dataset. Results show that our direct perception approach can generalize well to real driving images. Source code and data are available on our project website.

cv-foundation.org

ẤN BỐT ^

☆ Lưu 99 Trích dẫn Trích dẫn 2797 bài viết Bài viết có liên quan Tất cả 22 phiên bản >>



Các bài báo nền tảng(3)

- ✓ Phát hiện Lane
 - ✓ Phát hiện phương tiện
 - ✓ Drivable Area
- ✗ Yêu cầu thiết bị

Vấn đề giải quyết


Computation, inference time, tài nguyên phần cứng.

Vì YOLOP gom ba bài toán thành 1 mạng **multi-task** thay vì chạy **ba model riêng** :

- + Object Detection model
- + Drivable Area model
- + Lane Detection model

Output thực tế

Tạo perception tổng hợp để xe biết xe ở đâu, vùng nào chạy được và lane ở đâu.



Yolop: You only look once for panoptic driving perception

D Wu, MW Liao, WT Zhang, XG Wang, X Bai, WQ Cheng, WY Liu

Machine Intelligence Research, 2022 · Springer

Abstract

A panoptic driving perception system is an essential part of autonomous driving. A high-precision and real-time perception system can assist the vehicle in making reasonable decisions while driving. We present a panoptic driving perception network (you only look once for panoptic (YOLOP)) to perform traffic object detection, drivable area segmentation, and lane detection simultaneously. It is composed of one encoder for feature extraction and three decoders to handle the specific tasks. Our model performs extremely well on the challenging BDD100K dataset, achieving state-of-the-art on all three tasks in terms of accuracy and speed. Besides, we verify the effectiveness of our multi-task learning model for joint training via ablative studies. To our best knowledge, this is the first work that can process these three visual perception tasks simultaneously in real-time on an embedded device Jetson TX2(23 FPS), and maintain excellent accuracy. To facilitate further research, the source codes and pre-trained models are released at <https://github.com/hustvl/YOLOP>.

Springer

ẨN BÓT ^

☆ Lưu Trích dẫn Trích dẫn 597 bài viết Bài viết có liên quan Tất cả 8 phiên bản

Các bài báo nền tảng(3)




Fig. 2 The architecture of YOLOP. YOLOP shares one encoder and combines three decoders to solve different tasks. The encoder consists of a backbone and a neck.

YOLOP sử dụng **một encoder** chung để trích xuất đặc trưng từ ảnh. Sau đó đặc trưng được chia cho ba nhánh xử lý gồm phát hiện **phương tiện**, phân đoạn vùng có thể di chuyển và phân đoạn vạch làn. Kiến trúc **multi-task** này giúp giảm việc sử dụng nhiều mô hình riêng biệt và cho phép xử lý cả ba nhiệm vụ đồng thời.

Yolop: You only look once for panoptic driving perception

D Wu, MW Liao, WT Zhang, XG Wang, X Bai, WQ Cheng, WY Liu

Machine Intelligence Research, 2022 • Springer

Abstract

A panoptic driving perception system is an essential part of autonomous driving. A high-precision and real-time perception system can assist the vehicle in making reasonable decisions while driving. We present a panoptic driving perception network (you only look once for panoptic (YOLOP)) to perform traffic object detection, drivable area segmentation, and lane detection simultaneously. It is composed of one encoder for feature extraction and three decoders to handle the specific tasks. Our model performs extremely well on the challenging BDD100K dataset, achieving state-of-the-art on all three tasks in terms of accuracy and speed. Besides, we verify the effectiveness of our multi-task learning model for joint training via ablative studies. To our best knowledge, this is the first work that can process these three visual perception tasks simultaneously in real-time on an embedded device Jetson TX2(23 FPS), and maintain excellent accuracy. To facilitate further research, the source codes and pre-trained models are released at <https://github.com/hustvl/YOLOP>.

Springer

ẨN BÓT ^

☆ Lưu 77 Trích dẫn Trích dẫn 597 bài viết Bài viết có liên quan Tất cả 8 phiên bản

Khảo sát các bài báo gần hướng (1)

Vấn đề giải quyết


A-YOLOM tập trung vào **ba yêu cầu** quan trọng của **hệ thống lái tự động**:

- + Độ chính xác cao (high precision)
- + Mô hình nhẹ (lightweight)
- + Xử lý thời gian thực (real-time)

Output thực tế

Object Detection, Drivable Area Segmentation, Lane Line Segmentation

YOLOP



A-YOLOM(n)



A-YOLOM(s)



JOURNAL OF LATEX CLASS FILES, VOL. 14, NO. 8, AUGUST 2021

You Only Look at Once for Real-Time and Generic Multi-Task

Jiayuan Wang, *Graduate Student Member, IEEE*, Q. M. Jonathan Wu, *Senior Member, IEEE*, and Ning Zhang, *Senior Member, IEEE*

Abstract—High precision, lightweight, and real-time responsiveness are three essential requirements for implementing autonomous driving. In this study, we incorporate A-YOLOM, an adaptive, real-time, and lightweight multi-task model designed to concurrently address object detection, drivable area segmentation, and lane line segmentation tasks. Specifically, we develop an end-to-end multi-task model with a unified and streamlined segmentation structure. We introduce a learnable parameter that adaptively concatenates features between necks and backbone in segmentation tasks, using the same loss function for all segmentation tasks. This eliminates the need for customizations and enhances the model's generalization capabilities. We also introduce a segmentation head composed only of a series of convolutional layers, which reduces the number of parameters and inference time. We achieve competitive results on the BDD100k dataset, particularly in visualization outcomes. The performance results show a mAP50 of 81.1% for object detection, a mIoU of 91.0% for drivable area segmentation, and an IoU of 28.8% for lane line segmentation. Additionally, we introduce real-world scenarios to evaluate our model's performance in a real scene, which significantly outperforms competitors. This demonstrates that our model not only exhibits competitive performance but is also more flexible and faster than existing multi-task models. The source codes and pre-trained models are released at <https://github.com/JiayuanWang-JW/YOLOv8-multi-task>

Index Terms—Multi-task learning, panoptic driving perception, object detection, drivable area segmentation, lane line segmentation




Fig. 1: Multi-task in autonomous driving: object detection, drivable area segmentation and lane line segmentation

model becomes a formidable solution. Additionally, high precision, real-time and lightweight are essential in autonomous driving tasks. In emergencies, ADS must fast and accurately decide to avoid potential collisions or safely around obstacles. Accurately and fast estimating the drivable area and lane lines is important for effective route planning. In fact, maintaining a frame rate exceeding 30 frames per second (FPS) is imperative for ADS [4], [5]. Given the limited computational

0.01641v4 [cs.CV] 24 Apr 2024

Khảo sát các bài báo gần hướng (1)

Backbone – trích xuất đặc trưng chung

Nhiệm vụ + nhận ảnh đầu vào

- + trích xuất **feature** ở nhiều mức;
- + các **feature** này được dùng chung cho cả:

Object Detection, Drivable Area Segmentation, Lane Line Segmentation.

Backbone dùng chung để trích xuất đặc trưng đa mức từ ảnh đầu vào, giúp giảm việc tính toán lặp lại giữa các nhiệm vụ.

Detect Neck

lấy feature từ nhiều mức của Backbone, sau đó dùng:

- + **US** – Upsampling: tăng kích thước feature map;
- + **C** – Concatenate: nối các feature từ nhiều tầng;
- + **C2f**: xử lý và tinh chỉnh feature;
- + **CBS**: Convolution + Batch Normalization + SiLU.

Feature nông (shallow feature) = đặc trưng lấy ở những tầng gần ảnh đầu vào. Nó còn giữ nhiều thông tin về vị trí, cạnh, đường viền, chi tiết nhỏ. (VD cạnh xe nằm ?, kích thước ?)

Feature sâu (deep feature) = đặc trưng lấy ở những tầng sâu hơn của backbone. Nó đã qua nhiều lớp xử lý nên hiểu tốt hơn “đây là xe”, “đây là đường”, “đây là lane”, nhưng thông tin vị trí chi tiết có thể bị giảm đi. (VD là xe?)




Fig. 2: A-YOLOM structure

Detect Head

Bbox : vị trí của phương tiện.

Cls : loại đối tượng

Khảo sát các bài báo gần hướng (1)

Segment Neck x N

× N có nghĩa là kiến trúc segmentation có thể được **lặp lại cho nhiều segmentation task**.

Trong bài toán hiện tại:
 một branch → Drivable Area
 một branch → Lane Line

A-YOLOM có tính **generic multi-task**: nếu sau này muốn thêm một segmentation task khác, về nguyên tắc có thể bổ sung một branch tương tự.


AC – Adaptive Concatenate

Phần **quan trọng** nhất để **phân biệt** A-YOLOM

Mục tiêu:

- + giảm việc thiết kế thủ công
- + tăng tính tổng quát;
- + cho phép cùng một kiến trúc segmentation áp dụng cho nhiều task khác nhau.

Adaptive Concatenate tự động lựa chọn/kết hợp đặc trưng phù hợp từ **Backbone** cho từng nhiệm vụ segmentation.



Segment Head

Để giảm tài nguyên

Output:

- + **Mask 1** Drivable Area Mask
- + **Mask 2** Lane Line Mask

Khảo sát các bài báo gần hướng (2)



Vấn đề giải quyết:

- + Giảm độ trễ khi phải sử dụng nhiều mạng riêng biệt cho: Lane Line Segmentation, Drivable Area Segmentation, Object Detection.
- + Cải thiện việc kết hợp đặc trưng đa tỉ lệ.
- + Tăng khả năng phát hiện phương tiện nhỏ hoặc ở xa.
- + Tối ưu độ chính xác và chi phí tính toán của mạng multi-task.

Output thực tế: Lane Line Segmentation, Drivable Area Segmentation, Traffic Object Detection

HybridNets: End-to-End Perception Network

VT Dat^a NVH Bao^a PD Hung^a

^a FPT University, Hoa Lac High Tech Park, Hanoi, 10000, Vietnam

datvthe140592@fpt.edu.vn, baonvhhe141782@fpt.edu.vn, hungpd2@fe.edu.vn

Received: xx, 2022

Abstract— End-to-end Network has become increasingly important in multi-tasking. One prominent example of this is the growing significance of a driving perception system in autonomous driving. This paper systematically studies an end-to-end perception network for multi-tasking and proposes several key optimizations to improve accuracy. First, the paper proposes efficient segmentation head and box/class prediction networks based on weighted bidirectional feature network. Second, the paper proposes automatically customized anchor for each level in the weighted bidirectional feature network. Third, the paper proposes an efficient training loss function and training strategy to balance and optimize network. Based on these optimizations, we have developed an end-to-end perception network to perform multi-tasking, including traffic object detection, drivable area segmentation and lane detection simultaneously, called HybridNets, which achieves better accuracy than prior art. In particular, HybridNets achieves **77.3 mean Average Precision** on Berkeley DeepDrive Dataset, outperforms lane detection with **31.6 mean Intersection Over Union** with **12.83 million** parameters and **15.6 billion** floating-point operations. In addition, it can perform visual perception tasks in real-time and thus is a practical and accurate solution to the multi-tasking problem. Code is available at <https://github.com/datvuthanh/HybridNets>.

Keywords: End-to-end network, multi-task learning, detection, segmentation, autonomous-driving.

1. INTRODUCTION


1.1. Background

Khảo sát các bài báo gần hướng (2)

(a) Day-time result



(b) Night-time result



Khảo sát các bài báo gần hướng (2)

Backbone – trích xuất đặc trưng chung

EfficientNet-B3

Nhiệm vụ:

- Nhận ảnh đầu vào.
- Trích xuất **feature ở nhiều mức**.
- Cung cấp feature cho các nhiệm vụ phía sau.

EfficientNet-B3 được chọn nhằm cân bằng giữa độ chính xác và chi phí tính toán.


Neck

BiFPN – Bidirectional Feature Pyramid Network

Nhiệm vụ:

- Lấy feature ở **nhiều độ phân giải**;
- Kết hợp theo hai hướng: **Top-down ↓, Bottom-up ↑**
- Học **trọng số** để xác định feature level nào quan trọng hơn.

BiFPN giúp kết hợp thông tin ngữ nghĩa của feature sâu với thông tin chi tiết từ các feature ở nhiều scale.



Detection Head

Output:

- **Bbox**: vị trí phương tiện
- **Cls**: loại đối tượng
- **Confidence**: độ tin cậy

HybridNets còn dùng **customized anchors** để phù hợp với kích thước vật thể trong dataset, đặc biệt hữu ích khi có xe lớn gần camera và xe rất nhỏ ở xa

Khảo sát các bài báo gần hướng (2)

Detection Head

Output:

- **Bbox**: vị trí phương tiện
- **Cls**: loại đối tượng
- **Confidence**: độ tin cậy

HybridNets còn dùng **customized anchors** để phù hợp với kích thước vật thể trong dataset, đặc biệt hữu ích khi có xe lớn gần camera và xe rất nhỏ ở xa


Segmentation Head

HybridNets không chỉ phát hiện object mà còn thực hiện **semantic segmentation**.

Segmentation Head phân loại mỗi pixel thành **3 lớp**:

- Background
- Drivable Area
- Lane Line

Feature từ nhiều mức của BiFPN được **upsample** về cùng kích thước → **kết hợp** → tạo **segmentation mask** cuối cùng.



Khảo sát các bài báo gần hướng (2)

Hạn chế:

- Tại giao lộ, lane line có thể bị gián đoạn.
- Drivable area có thể bị dự đoán sai sang phần đường khác.
- Chưa xác định trực tiếp **Ego-Lane**.




Khảo sát các bài báo gần hướng (3)

Vấn đề giải quyết:

- Chi phí tính toán cao: phân đoạn từng pixel tốn nhiều phép tính → chuyển sang **Row-based Selection** để tăng tốc.
- Lane bị che hoặc thiếu dấu hiệu trực quan: dùng **Global Features** để suy ra vị trí làn từ toàn cảnh.
- Khó giữ cấu trúc lane liên tục: dùng **Structural Loss** để học tính liên tục và hình dạng của làn.

Output thực tế: Dự đoán vị trí của từng lane tại các Row Anchor. → Các vị trí này được ghép lại thành **đường lane trên ảnh**.



arXiv:2004.11757v4 [cs.CV] 5 Aug 2020

Ultra Fast Structure-aware Deep Lane Detection *

Zequn Qin, Huanyu Wang, and Xi Li**[0000-0003-3023-1662]

College of Computer Science & Technology,
Zhejiang University, Hangzhou, China

zequnqin@gmail.com, {huanyuhello, xilizju}@zju.edu.cn

Abstract. Modern methods mainly regard lane detection as a problem of pixel-wise segmentation, which is struggling to address the problem of challenging scenarios and speed. Inspired by human perception, the recognition of lanes under severe occlusion and extreme lighting conditions is mainly based on contextual and global information. Motivated by this observation, we propose a novel, simple, yet effective formulation aiming at extremely fast speed and challenging scenarios. Specifically, we treat the process of lane detection as a row-based selecting problem using global features. With the help of row-based selecting, our formulation could significantly reduce the computational cost. Using a large receptive field on global features, we could also handle the challenging scenarios. Moreover, based on the formulation, we also propose a structural loss to explicitly model the structure of lanes. Extensive experiments on two lane detection benchmark datasets show that our method could achieve the state-of-the-art performance in terms of both speed and accuracy. A light weight version could even achieve 300+ frames per second with the same resolution, which is at least 4x faster than previous state-of-the-art methods. Our code is available at <https://github.com/cfzd/Ultra-Fast-Lane-Detection>.

Keywords: Lane detection, Fast formulation, Structural loss, Row anchor


1 Introduction

With a long research history in computer vision, lane detection is a fundamental problem and has a wide range of applications [8] (e.g., ADAS and autonomous driving). For lane detection, there are two kinds of mainstream methods, which are traditional image processing methods [2,28,1] and deep segmentation methods [11,22,21]. Recently, deep segmentation methods have made great success in this field because of great representation and learning ability. There are still some important and challenging problems to be addressed.

Khảo sát các bài báo gần hướng (3)



Khảo sát các bài báo gần hướng (3)



Row-based Selecting

Thay vì kiểm tra tất cả pixel: Chọn trước **h Row Anchors**.

Mỗi hàng chia thành **w grid cells**.

Với mỗi lane:

→ model chỉ cần chọn **cell nào chứa lane**.

Nếu không có lane tại hàng đó:

→ chọn **background cell**.

Segmentation truyền thống


Ảnh kích thước: **$H \times W$**

Model phải xác định class cho gần như từng pixel:

$H \times W \times (C + 1)$

→ số lượng phép phân loại rất lớn.

Khảo sát các bài báo gần hướng (3)



Global Features: sử dụng thông tin toàn ảnh để hỗ trợ nhận diện lane khi bị che hoặc thiếu dấu hiệu trực quan.


Structural Loss: khai thác tính **liên tục và hình dạng** của lane để dự đoán ổn định hơn.

Auxiliary Segmentation: chỉ dùng trong quá trình huấn luyện để hỗ trợ học đặc trưng, sau đó **được loại bỏ khi inference** nên không làm giảm tốc độ chạy.

Khảo sát các bài báo gần hướng (3)

Hạn chế:

- Hiệu quả giảm khi vạch làn gần như không tồn tại.
- Gặp khó khăn trong **ánh sáng chói/phức tạp**.
- Tại **giao lộ**, vẫn có thể xuất hiện phát hiện sai.
- Chỉ phát hiện lane, chưa có **Drivable Area / Vehicle / Ego-Lane**.




Khảo sát các bài báo gần hướng (4)

Vấn đề mà bài báo đặt ra

Trong ảnh giao thông thực tế, một làn đường có thể:

- Bị xe phía trước che khuất.
- Bị mất một đoạn vạch kẻ.
- Khó nhìn do bóng tối, bóng đổ hoặc ánh sáng chói.
- Chỉ có một phần nhỏ xuất hiện trong ảnh.

Đầu ra: duy trì tốc độ cao nhưng vẫn sử dụng ngữ cảnh toàn cục để xử lý lane bị che, thiếu vạch hoặc không đủ bằng chứng trực quan.



Keep your Eyes on the Lane: Real-time Attention-guided Lane Detection

Lucas Tabelini¹, Rodrigo Berriel¹, Thiago M. Paixão²,
Claudine Badue¹, Alberto F. De Souza¹, Thiago Oliveira-Santos¹

¹Universidade Federal do Espírito Santo (UFES) ²Instituto Federal do Espírito Santo (IFES)

tabelini@icad.inf.ufes.br

Abstract

Modern lane detection methods have achieved remarkable performances in complex real-world scenarios, but many have issues maintaining real-time efficiency, which is important for autonomous vehicles. In this work, we propose LaneATT: an anchor-based deep lane detection model, which, akin to other generic deep object detectors, uses the anchors for the feature pooling step. Since lanes follow a regular pattern and are highly correlated, we hypothesize that in some cases global information may be crucial to infer their positions, especially in conditions such as occlusion, missing lane markers, and others. Thus, this work proposes a novel anchor-based attention mechanism that aggregates global information. The model was evaluated extensively on three of the most widely used datasets in the literature. The results show that our method outperforms the current state-of-the-art methods showing both higher efficacy and efficiency. Moreover, an ablation study is performed along with a discussion on efficiency trade-off options that are useful in practice. Code and models are available at <https://github.com/lucastabelini/LaneATT>.

1. Introduction

Deep learning has been essential for recent advances in numerous areas, especially in autonomous driving [2]. Many

may also suffer from a data imbalance problem caused by the long-tail effect since cases with sharper curves are less common. Besides, the model not only has to be robust but also efficient. In several applications, lane detection must perform in real-time, or faster to save processing power for other systems, a requirement that many models struggle to cope with.

There are numerous works in the literature that tackle this problem. Before the advent of deep learning, several methods used more traditional computer vision techniques, such as Hough lines [4, 1]. More recently, focus has shifted to deep learning approaches with the advance of convolutional neural networks (CNNs) [17, 11, 18]. In this context, the lane detection problem is usually formulated as a segmentation task, where, given an input image, the output is a segmentation map with per-pixel predictions [17]. Although recent advances in deep learning have enabled the use of segmentation networks in real-time [22], various models struggle to achieve real-time performance. Consequently, the number of backbone options for segmentation-based methods is rather limited. Hence, some recent works have proposed solutions in other directions [13, 23]. Apart from that, many other issues are common in works on lane detection, such as the need for a post-processing step (usually a heuristic), long training times, and a lack of publicly available source code, which hinders comparisons and reproducibility.

Trọng tâm: dùng quan hệ giữa các lane để bù cho phần lane không quan sát được.

Khảo sát các bài báo gần hướng (4)

1. Backbone: Ảnh được đưa qua ResNet để tạo feature map. Bài báo khảo sát ba cấu hình:

ResNet-18.

ResNet-34.

ResNet-122.

ResNet-18 là phiên bản nhẹ nhất và có tốc độ cao nhất.

2. Anchor-based feature pooling: Với mỗi anchor, LaneATT chiếu các điểm của anchor lên feature map và lấy đặc trưng tại những vị trí đó. mô hình lấy đặc trưng dọc theo hình dạng lane giả định, thay vì sử dụng toàn bộ feature map hoặc chỉ lấy đặc trưng tại một điểm.


3. Attention giữa các anchor: Mỗi anchor được phép thu nhận thông tin từ các anchor khác thông qua attention.

Ví dụ, nếu lane bên trái bị xe che một phần, đặc trưng của các lane còn lại có thể cung cấp ngữ cảnh về:

Hướng chung của mặt đường.

Độ cong của hệ thống lane.

Quan hệ không gian giữa các làn.



4. Dự đoán và NMS:

Với mỗi anchor, mô hình dự đoán:

Xác suất anchor chứa lane.

Tọa độ hiệu chỉnh cho hình dạng lane.

Phần bắt đầu và chiều dài của lane.

Sau đó, NMS loại bỏ các lane trùng nhau. Tác giả chỉ ra rằng NMS là một trong những nút thắt inference vì thời gian xử lý phụ thuộc vào số lượng proposal được giữ lại.

Khảo sát các bài báo gần hướng (4)



Kết luận:

Đối với hệ thống hạn chế tài nguyên, **LaneATT-ResNet18** là cấu hình đáng khảo sát nhất vì:

- 9,3 G MACs, thấp nhất trong ba cấu hình.
- CULane F1 75,09 tại 250 FPS theo báo cáo.
- Chênh lệch độ chính xác với ResNet-34 không quá lớn.
- Dùng lane representation thay vì dense segmentation mask.

Những hạn chế:

- FPS được đo trên GPU trong môi trường thực nghiệm của bài báo, không phải vi điều khiển, FPGA hay embedded SoC.
- Bài báo không báo cáo công suất, RAM, mức tiêu thụ năng lượng hoặc kết quả INT8.
- NMS vẫn là thành phần hậu xử lý và được tác giả xác định là nút thắt.
- Cấu hình có nhiều anchor hơn không phải lúc nào cũng tốt hơn.




Khảo sát các bài báo gần hướng (5)

Vấn đề mà bài báo đặt ra

- Phân biệt các lane instance nằm gần nhau
- Phát hiện topology phức tạp như lane phân nhánh hoặc nhiều lane dày đặc

Cách giải quyết: CondLaneNet sử dụng cách tiếp cận **top-to-down**:

1. Tìm lane instance trước.
2. Sinh một kernel riêng cho instance đó.
3. Dùng kernel để dự đoán hình dạng của lane.



CondLaneNet: a Top-to-down Lane Detection Framework Based on Conditional Convolution

Lizhe Liu¹ Xiaohao Chen¹ Siyu Zhu¹ Ping Tan^{1,2}
¹Alibaba Group ²Simon Fraser University

Abstract

Modern deep-learning-based lane detection methods are successful in most scenarios but struggling for lane lines with complex topologies. In this work, we propose CondLaneNet, a novel top-to-down lane detection framework that detects the lane instances first and then dynamically predicts the line shape for each instance. Aiming to resolve lane instance-level discrimination problem, we introduce a conditional lane detection strategy based on conditional convolution and row-wise formulation. Further, we design the Recurrent Instance Module (RIM) to overcome the problem of detecting lane lines with complex topologies such as dense lines and fork lines. Benefit from the end-to-end pipeline which requires little post-process, our method has real-time efficiency. We extensively evaluate our method on three benchmarks of lane detection. Results show that our method achieves state-of-the-art performance on all three benchmark datasets. Moreover, our method has the coexistence of accuracy and efficiency, e.g. a 78.14 F1 score and 220 FPS on CULane. Our code is available at <https://github.com/aliyun/conditional-lane-detection>.

1. Introduction

Artificial intelligence technology is increasingly being used in the driving field, which is conducive to autonomous driving and the Advanced Driver Assistance System (ADAS). As a basic problem in autonomous driving, lane detection plays a vital role in applications such as vehicle real-time positioning, driving route planning, lane-keeping assist, and adaptive cruise control.

Traditional lane detection methods usually rely on hand-




Figure 1. Scenes of lane lines with complex topologies. It is challenging to cope with the scenes such as the dense lines (the first row) and the fork lines (the second row). Different instances are represented by different colors in this figure.

studies about lane detection have focused on deep learning [34]. Early deep-learning-based methods detect lane lines through segmentation [28, 27]. Recently, various methods such as anchor-based methods [32, 2, 39], row-wise detection methods [30, 29, 41], and parametric prediction methods [31, 25] have been proposed and continue to refresh the accuracy and efficiency. Although deep-learning-based lane detection methods have made great progress [42], there are still many challenges.

A common problem for lane detection is instance-level discrimination. Most lane detection methods [27, 28, 19, 32, 12, 21, 29, 2, 30, 41, 39] predict lane points first and then aggregate the points into lines. But assigning different points to different lane instances [34] is still a common challenge. A simple solution is to label the lane lines into classes of a fixed number (e.g. labeled as 0, 1, 2, 3 if the maximum lane number is 4) and make a multi-class classification [28, 30, 41, 3]. But the limitation is that only a predefined, fixed number of lanes can be detected [27]. To overcome this limitation, the post-clustering strategy is investigated [27, 19]. However, this strategy is struggling for some cases such as dense lines. Another approach is

Trọng tâm: tách từng instance trước khi mô tả hình dạng lane.

Khảo sát các bài báo gần hướng (5)

1. Backbone + Transformer: tạo đặc trưng đa tỉ lệ và ngữ cảnh cho proposal detection.

2. Proposal head: Proposal head xác định vị trí đại diện hoặc điểm bắt đầu của từng lane.

Nó sinh ra:

- **Proposal heatmap:** vị trí có khả năng chứa một lane instance.

- **Parameter map:** các tham số dùng để tạo dynamic kernel cho lane đó.


3. Dynamic kernel: Tại mỗi proposal được phát hiện, mô hình lấy một vector tham số từ parameter map. Vector này được chuyển thành kernel riêng cho lane instance. Kernel được áp dụng lên shared feature map để lấy ra hình dạng của lane tương ứng.

4. Row-wise lane formulation: CondLaneNet không dự đoán toàn bộ mask dày đặc. Thay vào đó, với mỗi hàng y , mô hình dự đoán vị trí ngang x của lane.

Cách biểu diễn này phù hợp với đặc tính hình học của lane, vì phần lớn lane có thể được mô tả bằng một vị trí ngang tại từng hàng ảnh.

5. Offset refinement: Dự đoán row-wise ban đầu có độ phân giải rời rạc. Offset branch dự đoán độ lệch bổ sung để tinh chỉnh tọa độ ngang của lane.

Thêm offset làm F1 tăng từ 80,09 lên 81,24 trong ablation của bài báo.



Recurrent Instance Module — RIM:

Một proposal thông thường tạo ra một kernel và một lane.

Cách này chưa đủ khi một lane xuất phát từ một vùng nhưng sau đó phân thành nhiều nhánh. Nhờ đó, một proposal có thể tạo ra nhiều lane liên quan đến cùng một cấu trúc phân nhánh.

Khảo sát các bài báo gần hướng (5)


Kết luận:

CondLaneNet-Small là phiên bản phù hợp nhất để nghiên cứu trong điều kiện giới hạn tài nguyên vì:

- Sử dụng ResNet-18.
- Chi phí 10,2 GFLOPs.
- Đạt CULane F1 78,14.
- Dùng row-wise representation thay vì mask toàn ảnh.
- Có cơ chế phân biệt từng lane bằng instance-specific kernel.

Những hạn chế:

- Kết quả tốc độ được đo trên RTX 2080, không phải phần cứng nhúng.
- Bài báo không đánh giá quantization, công suất, RAM hay nhiệt độ.
- Dynamic kernel và Transformer encoder có thể ảnh hưởng đến khả năng triển khai, nhưng bài báo không cung cấp benchmark riêng cho chúng trên embedded accelerator.
- Không được dùng kết quả của RIM để tuyên bố cải thiện trên CULane hoặc TuSimple.



Khảo sát các bài báo gần hướng (6)

- ✓ Xử lý vấ đề Lane bị mờ / mất
- ✗ Hệ thống phức tạp
- ✗ Chỉ tập trung vào lane

Vấn đề giải quyết:

Các phương pháp lane thông thường phụ thuộc vào việc camera phải nhìn thấy:

- vạch lane;
- biên đường;
- feature trên mặt đường.

Nhưng trong thực tế có thể xảy ra Lane mờ → Lane bị che → gần như không còn Lane Feature

Khi đó chỉ cố dùng thuật toán phát hiện feature mạnh hơn vẫn có thể thất bại và tốn nhiều thời gian xử lý.

Bài báo giải quyết việc Ego-Lane bị mất do thiếu lane feature bằng cách dùng hình dạng đường từ bản đồ làm thông tin tham chiếu, nhờ đó vẫn ước lượng được hai biên Ego-Lane ngay cả khi camera thấy rất ít hoặc không thấy rõ vạch lane.

Output thực tế

Ước lượng hai biên Ego-Lane, xác định vùng làn đường mà xe đang di chuyển ngay cả khi lane feature bị thiếu hoặc khó quan sát.

Map-Enhanced Ego-Lane Detection in the Missing Feature Scenarios

XIAOLIANG WANG¹, YEQIANG QIAN¹, (Graduate Student Member, IEEE),
CHUNXIANG WANG¹, AND MING YANG¹, (Member, IEEE)


Department of Automation, Shanghai Jiao Tong University, Shanghai 200240, China

Corresponding author: Ming Yang (mingyang@sjtu.edu.cn)

This work was supported by the National Natural Science Foundation of China under Grant U1764264/61873165.

ABSTRACT As one of the most important tasks in autonomous driving systems, ego-lane detection has been extensively studied and has achieved impressive results in many scenarios. However, ego-lane detection in the missing feature scenarios is still an unsolved problem. To address this problem, previous methods have been devoted to proposing more complicated feature extraction algorithms, but they are very time-consuming and cannot deal with extreme scenarios. Different from others, this paper exploits prior knowledge contained in digital maps, which has a strong capability to enhance the performance of detection algorithms. Specifically, we employ the road shape extracted from OpenStreetMap as lane model, which is highly consistent with the real lane shape and irrelevant to lane features. In this way, only a few lane features are needed to eliminate the position error between the road shape and the real lane, and a search-based optimization algorithm is proposed. Experiments show that the proposed method can be applied to various scenarios and can run in real-time at a frequency of 20 Hz. At the same time, we evaluated the proposed method on the public KITTI Lane dataset where it achieves state-of-the-art performance. Moreover, our code will be open source after publication.

Khảo sát các bài báo gần hướng (6)



Map-Enhanced Ego-Lane Detection in the Missing Feature Scenarios

XIAOLIANG WANG^{ID}, YEQIANG QIAN^{ID}, (Graduate Student Member, IEEE),
CHUNXIANG WANG^{ID}, AND MING YANG^{ID}, (Member, IEEE)

Department of Automation, Shanghai Jiao Tong University, Shanghai 200240, China

Corresponding author: Ming Yang (mingyang@sjtu.edu.cn)

This work was supported by the National Natural Science Foundation of China under Grant U1764264/61873165.

ABSTRACT As one of the most important tasks in autonomous driving systems, ego-lane detection has been extensively studied and has achieved impressive results in many scenarios. However, ego-lane detection in the missing feature scenarios is still an unsolved problem. To address this problem, previous methods have been devoted to proposing more complicated feature extraction algorithms, but they are very time-consuming and cannot deal with extreme scenarios. Different from others, this paper exploits prior knowledge contained in digital maps, which has a strong capability to enhance the performance of detection algorithms. Specifically, we employ the road shape extracted from OpenStreetMap as lane model, which is highly consistent with the real lane shape and irrelevant to lane features. In this way, only a few lane features are needed to eliminate the position error between the road shape and the real lane, and a search-based optimization algorithm is proposed. Experiments show that the proposed method can be applied to various scenarios and can run in real-time at a frequency of 20 Hz. At the same time, we evaluated the proposed method on the public KITTI Lane dataset where it achieves state-of-the-art performance. Moreover, our code will be open source after publication.

Bài báo sử dụng :

- **LiDAR** xác định vùng mặt đường cần xử lý (ROI).
- **Camera** trích xuất các lane feature còn nhìn thấy.
- **OpenStreetMap(OSM)** cung cấp hình dạng con đường làm lane model tham chiếu.
- Dùng search-based optimization để căn chỉnh road model từ OSM với các lane feature thực tế.
- Sau cùng xác định biên trái + biên phải + vùng Ego-Lane của xe.



Khi lane feature bị thiếu, hệ thống không hoàn toàn phụ thuộc vào camera mà sử dụng hình dạng đường từ bản đồ để bù lại thông tin bị mất.

Khảo sát các bài báo gần hướng (6)

Kết luận:

- Các hình ảnh kết quả cho thấy Ego-Lane vẫn được phát hiện trong trường hợp: lane bị mòn; vật thể che lane; vào tunnel; vùng lane bị quá tối/sáng; gần như không còn lane feature.
- MELD không chỉ đạt MaxF 93.56% cao nhất trên KITTI Lane trong nhóm so sánh, mà còn duy trì tốt hơn khi lane feature bị thiếu so với các mô hình hình học truyền thống.

Những hạn chế:

- Chỉ kiểm chứng trên một loại đường là two-way road chưa kiểm chứng trên multi-lane road; giao lộ; đường không có centerline.
- Độ chính xác phụ thuộc vào map và vị trí xe, OpenStreetMap vẫn có sai số

TABLE 1. Results of online evaluation on KITTI Lane benchmark. Best scores are highlighted in bold.

Method	MaxF	AP	PRE	REC	FPR	FNR	Runtime
SCRFFPHGSP [21]	57.22 %	39.34 %	41.78 %	90.79 %	22.28 %	9.21 %	5 s / CPU
SPlane + BL [22]	69.63 %	73.78 %	80.01 %	61.63 %	2.71 %	38.37 %	2 s / CPU
SPRAY [23]	83.42 %	86.84 %	84.76 %	82.12 %	2.60 %	17.88 %	0.045 s / GPU
Up-Conv-Poly [24]	89.88 %	87.52 %	92.01 %	87.84 %	1.34 %	12.16 %	0.08 s / GPU
RBNNet [25]	90.54 %	82.03 %	94.92 %	86.56 %	0.82 %	13.44 %	0.18 s / GPU
MANLDF	91.37 %	91.40 %	93.08 %	89.71 %	1.17 %	10.29 %	0.05 s / GPU
RoadNet3 [26]	91.47 %	91.01 %	91.17 %	91.78 %	1.44 %	8.83 %	0.3 s / GPU
NVLaneNet	91.86 %	91.42 %	90.89 %	92.85 %	1.64 %	7.15 %	0.08 s / GPU
MELD	93.56 %	88.58 %	95.94 %	91.30 %	0.68 %	8.70 %	0.05 s / CPU




FIGURE 11. Qualitative results of MELD. Each column represents a typical missing feature scenario, where the top row is the raw image and the bottom row is the detection result (shown as green) on the bird's eye view of image.

Figure 9.

It can be seen that the fitting results of all mathematical representation models become worse as the number of features decreases. However, since the OSM road shape is used as the lane model, MELD is very robust to missing features. Even if the number of features decreases, the effect remains unchanged. At the same time, in some extreme scenarios, such as no visible features, we directly use OSM road shape as the lane boundary, and the MaxF can reach 88.23 %, while other mathematical representation models cannot handle this scenario.

D. RUNTIME

Since MELD is to be used on autonomous driving systems, the less runtime of the algorithm allows systems to

107966

E. QUALITATIVE RESULTS

Some detection results of MELD are shown in Figure 11. For the first two columns, the lane line is heavily worn and blocked by shadows or other objects. For the third and fourth columns, the vehicle is going to pass through the tunnel, and the lane line in the far-range is covered by black or white. For the last column, there are no visible lane features can be seen in the picture. All these scenarios have the missing feature problem, but MELD can stably detect the ego-lane.

V. CONCLUSION

In this study, we employ the OSM road shape as lane model to enhance our ego-lane detection algorithm, which is robust to the challenging scenarios of missing feature. At the same time, to eliminate the position error between the OSM data

VOLUME 8, 2020

X. Wang et al.: Map-Enhanced Ego-Lane Detection in the Missing Feature Scenarios

IEEE Access

and the real lane, a search-based optimization algorithm is proposed to improve the accuracy of the algorithm. We validate the proposed algorithm on the well-known KITTI Lane benchmark, which achieved state-of-the-art performance in terms of accuracy and real-time performance. However, the proposed method has only been validated on the two-way road in which the vehicle is driving on the right lane like KITTI Lane dataset. In future work, we will expand our work to more general roads like multi-lane, intersection, and even no centerline. At the same time, to obtain more accurate ego-lane detection results, the OSM road shape error will also be eliminated.

- [20] D. Vajak, M. Vranješ, R. Grbić, and D. Vranješ, "Recent advances in vision-based lane detection solutions for automotive applications," in *Proc. Int. Symp. ELMAR*, Sep. 2019, pp. 45–50.
- [21] I. V. Gheorghe, "Semantic segmentation of terrain and road terrain for advanced driver assistance systems," Ph.D. dissertation, Dept. Eng. Comput., Coventry Univ., Coventry, U.K., 2015.
- [22] N. Einecke and J. Eggert, "Block-matching stereo with relaxed fronto-parallel assumption," in *Proc. IEEE Intell. Vehicles Symp.*, Jun. 2014, pp. 700–705.
- [23] T. Kühnl, F. Kummert, and J. Fritsch, "Spatial ray features for real-time ego-lane extraction," in *Proc. 15th Int. IEEE Conf. Intell. Transp. Syst.*, Sep. 2012, pp. 288–293.
- [24] G. Oliveira, W. Burgard, and T. Brox, "Efficient deep methods for monocular road segmentation," in *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst. (IROS)*, 2016, pp. 4885–4891.
- [25] Z. Chen and Z. Chen, "RBNNet: A deep neural network for unified road and

Khảo sát các bài báo gần hướng (7)

- ✓ Phát hiện Lane
 - ✓ Phát hiện phương tiện
 - ✓ Drivable Area
- ✗ Chưa giải quyết vấn đề lane mất/mờ

Vấn đề giải quyết

TriLiteNet vì vậy hướng tới:

- Một mô hình multi-task nhẹ, thực hiện đồng thời ba nhiệm vụ phát hiện phương tiện phía trước, vùng có thể di chuyển, vạch lane nhưng vẫn giữ chi phí tính toán thấp để phù hợp embedded systems.

Output thực tế

- Tạo perception tổng hợp để xe biết xe ở đâu, vùng nào chạy được và vạch lane ở đâu.
- Chạy và so sánh latency, power trên 2 board NVIDIA Jetson Xavier và NVIDIA Jetson TX2

TriLiteNet

Lightweight Model for Multi-Task Visual Perception

Quang-Huy Che^{*†}, Duc-Khai Lam^{†‡}

^{*}Laboratory of Multimedia Communications, University of Information Technology, Ho Chi Minh City, Vietnam

[†]Faculty of Computer Engineering, University of Information Technology, Ho Chi Minh City, Vietnam

[‡]Vietnam National University, Ho Chi Minh City, Vietnam

Email: huycq@uit.edu.vn, khaild@uit.edu.vn

Abstract—Efficient perception models are essential for Advanced Driver Assistance Systems (ADAS), as these applications require rapid processing and response to ensure safety and effectiveness in real-world environments. To address the real-time execution needs of such perception models, this study introduces the TriLiteNet model. This model can simultaneously manage multiple tasks related to panoramic driving perception. TriLiteNet is designed to optimize performance while maintaining low computational costs. Experimental results on the BDD100k dataset demonstrate that the model achieves competitive performance across three key tasks: vehicle detection, drivable area segmentation, and lane line segmentation. Specifically, the TriLiteNet_{base} demonstrated a recall of 85.6% for vehicle detection, a mean Intersection over Union (mIoU) of 92.4% for drivable area segmentation, and an Acc of 82.3% for lane line segmentation with only 2.35M parameters and a computational cost of 7.72 GFLOPs. Our proposed model includes a *tiny* configuration with just 0.14M parameters, which provides a multi-task solution with minimal computational demand. Evaluated for latency and power consumption on embedded devices, TriLiteNet in both configurations shows low latency and reasonable power during inference. By balancing performance, computational efficiency, and scalability, TriLiteNet offers a practical and deployable solution for real-world autonomous driving applications. Code is available at <https://github.com/chequanghuy/TriLiteNet>.

- Vehicle detection** identifies the coordinates of traffic objects, assisting the vehicle in predicting and reacting to potential collision risks.
- Drivable area segmentation** defines regions where vehicles can operate safely, enabling precise control predictions.
- Lane segmentation** provides detailed information about lanes, supporting the vehicle in maintaining or changing lanes securely.

When these three tasks are integrated, autonomous vehicles can comprehensively understand their environment, enabling more accurate and efficient decision-making. Many deep learning models, particularly Convolutional Neural Networks (CNNs), have significantly succeeded in panoramic driving perception tasks. Single-task models have demonstrated promising performance in various applications: [1]–[4] for vehicle detection, [5]–[7] for drivable area segmentation, and [8], [9] for lane segmentation. However, these single-task models are limited to handling only one task at a time, necessitating multiple models to obtain outputs for different tasks. This



Khảo sát các bài báo gần hướng (7)




Fig. 1: TriLiteNet is a unified encoder-decoder network consisting of a shared encoder and three separate decoders for different tasks: vehicle detection, drivable area segmentation, and lane line segmentation. In the encoding stage, the TwinLiteNet⁺ encoder block is adapted to extract features that are subsequently directed to distinct decoder blocks. For segmentation tasks, the two segmentation heads are designed similarly, taking the output of the PCAA block as input. In contrast, the decoder for vehicle detection includes LitePAN and SPP blocks to enhance feature extraction, particularly for small and complex objects. This process generates three feature maps of different scales, which are then fed into the object detection head for improved detection performance. Additionally, I_1 and I_2 are lower-resolution input images obtained through average pooling operations, which effectively downsample the input image while preserving essential contextual information. These downsampled images are concatenated with feature maps during the encoding and decoding of the segmentation tasks, enhancing the information flow across different resolution levels.

Hệ thống gồm 1 ảnh đầu vào → 1 bộ giải mã đặc trưng chung → chia ra 3 nhánh để xử lý 3 nhiệm vụ.

Shared Encoder: đọc ảnh camera và lấy các đặc trưng quan trọng như cạnh, hình dạng xe, cấu trúc mặt đường.

- **Nhánh Vehicle Detection:** dùng SPP + LitePAN để kết hợp đặc trưng ở nhiều kích thước, giúp phát hiện xe gần, xa, lớn, nhỏ.
- **Nhánh Lane Segmentation:** dùng PCAA để làm nổi bật thông tin liên quan đến vạch làn.
- **Nhánh Drivable Area Segmentation:** cũng dùng feature từ PCAA để xác định vùng đường có thể di chuyển.



Kiến trúc này là 3 nhiệm vụ dùng chung encoder, nên không phải chạy 3 mô hình riêng. Nhờ vậy mô hình nhẹ hơn, giảm tính toán và phù hợp hơn với thiết bị nhúng.

TriLiteNet

Lightweight Model for Multi-Task Visual Perception

Quang-Huy Che^{*†}, Duc-Khai Lam^{†‡}

^{*}Laboratory of Multimedia Communications, University of Information Technology, Ho Chi Minh City, Vietnam

[†]Faculty of Computer Engineering, University of Information Technology, Ho Chi Minh City, Vietnam

[‡]Vietnam National University, Ho Chi Minh City, Vietnam

Email: huycq@uit.edu.vn, khaild@uit.edu.vn

Abstract—Efficient perception models are essential for Advanced Driver Assistance Systems (ADAS), as these applications require rapid processing and response to ensure safety and effectiveness in real-world environments. To address the real-time execution needs of such perception models, this study introduces the TriLiteNet model. This model can simultaneously manage multiple tasks related to panoramic driving perception. TriLiteNet is designed to optimize performance while maintaining low computational costs. Experimental results on the BDD100k dataset demonstrate that the model achieves competitive performance across three key tasks: vehicle detection, drivable area segmentation, and lane line segmentation. Specifically, the TriLiteNet_{base} demonstrated a recall of 85.6% for vehicle detection, a mean Intersection over Union (mIoU) of 92.4% for drivable area segmentation, and an Acc of 82.3% for lane line segmentation with only 2.35M parameters and a computational cost of 7.72 GFLOPs. Our proposed model includes a *tiny* configuration with just 0.14M parameters, which provides a multi-task solution with minimal computational demand. Evaluated for latency and power consumption on embedded devices, TriLiteNet in both configurations shows low latency and reasonable power during inference. By balancing performance, computational efficiency, and scalability, TriLiteNet offers a practical and deployable solution for real-world autonomous driving applications. Code is available at <https://github.com/chequanghuy/TriLiteNet>.

- **Vehicle detection** identifies the coordinates of traffic objects, assisting the vehicle in predicting and reacting to potential collision risks.
- **Drivable area segmentation** defines regions where vehicles can operate safely, enabling precise control predictions.
- **Lane segmentation** provides detailed information about lanes, supporting the vehicle in maintaining or changing lanes securely.

When these three tasks are integrated, autonomous vehicles can comprehensively understand their environment, enabling more accurate and efficient decision-making. Many deep learning models, particularly Convolutional Neural Networks (CNNs), have significantly succeeded in panoramic driving perception tasks. Single-task models have demonstrated promising performance in various applications: [1]–[4] for vehicle detection, [5]–[7] for drivable area segmentation, and [8], [9] for lane segmentation. However, these single-task models are limited to handling only one task at a time, necessitating multiple models to obtain outputs for different tasks. This

*Thank you teacher and everyone for listening to the presentation. Have a **good** day*

