



TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH

Ho Chi Minh City University of Technology and Engineering



Improving the Reliability of AI-Based Lane Perception for Resource-Constrained Embedded Systems

Giáo viên hướng dẫn : TS. Phạm Văn Khoa

Sinh viên: Phạm Nguyễn Duy Phương

Đổng An Thịnh

Trần Vĩnh Kha

Võ Như Quyết

Nghành học: Công nghệ kỹ thuật

điện tử - viễn thông

Năm học: 2022-2026

Mã số sinh viên: 22161068

22161077

22161054

22161072

Lớp: 22161FIE1

Giới thiệu

Improving gồm **tăng độ tin cậy, độ chính xác, giảm độ trễ, bộ nhớ, ...**

AI-Based Lane Perception chuyên **nhận diện vạch làn, vùng có thể di chuyển, làn xe hiện tại, phương tiện/vật cản xung quanh, ...**

Resource-Constrained Embedded Systems hướng **đến các board nhúng phổ biến, chi phí thấp.**

Tiêu chí cần đặt ra ?

Lane Line, Drivable Area, Ego-Lane → các bài toán nhận thức làn đường bằng hình ảnh

Resource-Constrained Embedded Devices ?

- + Nhẹ (lightweight), chi phí thấp
- + **Memory efficient**
- + Công suất và năng lượng hạn chế

Làm nổi bật hướng đi

- + Reliable - lane không có vạch, mờ, thiếu, ...
- + **Low latency** - phù hợp xử lý gần thời gian thực
- + Tối ưu tài nguyên

Các bài báo nền tảng(1)



Phát hiện Lane



Chi phí cao



Độ chính xác cao



Yêu cầu thiết bị

Vấn đề giải quyết

Lane bị che khuất

Lane đứt đoạn

Ánh sáng yếu, chói sáng, thời tiết xấu


Output thực tế

Hỗ trợ xe nhận biết làn

Dẫn hướng

Driving-assistance systems

Mô hình SCNN đã giành giải nhất tại cuộc thi TuSimple Benchmark Lane Detection Challenge với độ chính xác đạt 96,53%.



Spatial as deep: Spatial cnn for traffic scene understanding

[X Pan](#), [J Shi](#), [P Luo](#), [X Wang](#), [X Tang](#)

Proceedings of the AAAI conference on artificial intelligence, 2018 • [ojs.aaai.org](#)

Abstract


Convolutional neural networks (CNNs) are usually built by stacking convolutional operations layer-by-layer. Although CNN has shown strong capability to extract semantics from raw pixels, its capacity to capture spatial relationships of pixels across rows and columns of an image is not fully explored. These relationships are important to learn semantic objects with strong shape priors but weak appearance coherences, such as traffic lanes, which are often occluded or not even painted on the road surface as shown in Fig. 1 (a). In this paper, we propose Spatial CNN (SCNN), which generalizes traditional deep layer-by-layer convolutions to slice-by-slice convolutions within feature maps, thus enabling message passings between pixels across rows and columns in a layer. Such SCNN is particular suitable for long continuous shape structure or large objects, with strong spatial relationship but less appearance clues, such as traffic lanes, poles, and wall. We apply SCNN on a newly released very challenging traffic lane detection dataset and Cityscape dataset. The results show that SCNN could learn the spatial relationship for structure output and significantly improves the performance. We show that SCNN outperforms the recurrent neural network (RNN) based ReNet and MRF+ CNN (MRFNet) in the lane detection dataset by 8.7% and 4.6% respectively. Moreover, our SCNN won the 1st place on the TuSimple Benchmark Lane Detection Challenge, with an accuracy of 96.53%.

[ojs.aaai.org](#)

ẤN BỐT ^

☆ Lưu  Trích dẫn Trích dẫn 1642 bài viết Bài viết có liên quan Tất cả 9 phiên bản 

Các bài báo nền tảng(1)



Spatial CNN (SCNN); mô hình này mở rộng phương pháp tích chập theo lớp truyền thống thành **tích chập theo từng lát cắt** (slice-by-slice) ngay trong các bản đồ đặc trưng (feature maps), qua đó cho phép **truyền tải thông tin giữa các điểm ảnh dọc theo hàng và cột trong cùng một lớp**. SCNN đặc biệt phù hợp với các đối tượng lớn hoặc có cấu trúc hình dạng dài và liên tục.

Spatial as deep: Spatial cnn for traffic scene understanding

X Pan, J Shi, P Luo, X Wang, X Tang

Proceedings of the AAAI conference on artificial intelligence, 2018 - ojs.aaai.org

Abstract

Convolutional neural networks (CNNs) are usually built by stacking convolutional operations layer-by-layer. Although CNN has shown strong capability to extract semantics from raw pixels, its capacity to capture spatial relationships of pixels across rows and columns of an image is not fully explored. These relationships are important to learn semantic objects with strong shape priors but weak appearance coherences, such as traffic lanes, which are often occluded or not even painted on the road surface as shown in Fig. 1 (a). In this paper, we propose Spatial CNN (SCNN), which generalizes traditional deep layer-by-layer convolutions to slice-by-slice convolutions within feature maps, thus enabling message passings between pixels across rows and columns in a layer. Such SCNN is particular suitable for long continuous shape structure or large objects, with strong spatial relationship but less appearance clues, such as traffic lanes, poles, and wall. We apply SCNN on a newly released very challenging traffic lane detection dataset and Cityscape dataset. The results show that SCNN could learn the spatial relationship for structure output and significantly improves the performance. We show that SCNN outperforms the recurrent neural network (RNN) based ReNet and MRF+ CNN (MRFNet) in the lane detection dataset by 8.7% and 4.6% respectively. Moreover, our SCNN won the 1st place on the TuSimple Benchmark Lane Detection Challenge, with an accuracy of 96.53%.

ojs.aaai.org

ẤN BỐT ^

☆ Lưu Trích dẫn Trích dẫn 1642 bài viết Bài viết có liên quan Tất cả 9 phiên bản >>

Các bài báo nền tảng(2)



Thông tin Lane



Hệ thống phức tạp



Thông tin phương tiện



Yêu cầu thiết bị

Vấn đề giải quyết (thời điểm đó có hai hướng)

+ Mediated Perception (nhận thức gián tiếp)

Camera xử lý phát hiện: + lane

+ biển báo

+ đèn giao thông

+ phương tiện,....

Vấn đề: quá nhiều thông tin, hệ thống phức tạp và tốn chi phí. cần laser range finder, GPS, radar và bản đồ chính xác.

+ Behavior Reflex (behavior reflex)

Camera → AI → Góc lái

Vấn đề: steering có thể trở nên mơ hồ (có xe phía trước theo, vượt trái hoặc vượt phải)

Output thực tế

Chuyển thông tin perception thành các driving affordances để controller quyết định lái xe.

Deepdriving: Learning affordance for direct perception in autonomous driving

C Chen, A Seff, A Kornhauser, J Xiao

Proceedings of the IEEE international conference on computer vision, 2015 • cv-foundation.org

Abstract

Today, there are two major paradigms for vision-based autonomous driving systems: mediated perception approaches that parse an entire scene to make a driving decision, and behavior reflex approaches that directly map an input image to a driving action by a regressor. In this paper, we propose a third paradigm: a direct perception approach to estimate the affordance for driving. We propose to map an input image to a small number of key perception indicators that directly relate to the affordance of a road/traffic state for driving. Our representation provides a set of compact yet complete descriptions of the scene to enable a simple controller to drive autonomously. Falling in between the two extremes of mediated perception and behavior reflex, we argue that our direct perception representation provides the right level of abstraction. To demonstrate this, we train a deep Convolutional Neural Network using recording from 12 hours of human driving in a video game and show that our model can work well to drive a car in a very diverse set of virtual environments. We also train a model for car distance estimation on the KITTI dataset. Results show that our direct perception approach can generalize well to real driving images. Source code and data are available on our project website.

cv-foundation.org

ẨN BỐT ^

☆ Lưu 77 Trích dẫn Trích dẫn 2797 bài viết Bài viết có liên quan Tất cả 22 phiên bản »



HCM-UTE

Các bài báo nền tảng(2)



AI xử lý thông tin : **góc** của xe so với hướng đường

khoảng cách từ xe đến lane markings

khoảng cách đến xe phía trước

khoảng cách đến xe trong lane hiện tại và lane bên cạnh.

=> xe lịch trái, phải nhiều , khoảng cách xe phía trước, tình trạng lane bên cạnh.

Deepdriving: Learning affordance for direct perception in autonomous driving

C Chen, A Seff, A Kornhauser, J Xiao

Proceedings of the IEEE international conference on computer vision, 2015 • cv-foundation.org


Abstract

Today, there are two major paradigms for vision-based autonomous driving systems: mediated perception approaches that parse an entire scene to make a driving decision, and behavior reflex approaches that directly map an input image to a driving action by a regressor. In this paper, we propose a third paradigm: a direct perception approach to estimate the affordance for driving. We propose to map an input image to a small number of key perception indicators that directly relate to the affordance of a road/traffic state for driving. Our representation provides a set of compact yet complete descriptions of the scene to enable a simple controller to drive autonomously. Falling in between the two extremes of mediated perception and behavior reflex, we argue that our direct perception representation provides the right level of abstraction. To demonstrate this, we train a deep Convolutional Neural Network using recording from 12 hours of human driving in a video game and show that our model can work well to drive a car in a very diverse set of virtual environments. We also train a model for car distance estimation on the KITTI dataset. Results show that our direct perception approach can generalize well to real driving images. Source code and data are available on our project website.

cv-foundation.org

ẤN BỐT ^

☆ Lưu 99 Trích dẫn Trích dẫn 2797 bài viết Bài viết có liên quan Tất cả 22 phiên bản >>



Các bài báo nền tảng(3)

- ✓ Phát hiện Lane
 - ✓ Phát hiện phương tiện
 - ✓ Drivable Area
- ✗ Yêu cầu thiết bị

Vấn đề giải quyết


Computation, inference time, tài nguyên phần cứng.

Vì YOLOP gom ba bài toán thành 1 mạng **multi-task** thay vì chạy **ba model riêng** :

- + Object Detection model
- + Drivable Area model
- + Lane Detection model

Output thực tế

Tạo perception tổng hợp để xe biết xe ở đâu, vùng nào chạy được và lane ở đâu.



Yolop: You only look once for panoptic driving perception

D Wu, MW Liao, WT Zhang, XG Wang, X Bai, WQ Cheng, WY Liu

Machine Intelligence Research, 2022 · Springer

Abstract

A panoptic driving perception system is an essential part of autonomous driving. A high-precision and real-time perception system can assist the vehicle in making reasonable decisions while driving. We present a panoptic driving perception network (you only look once for panoptic (YOLOP)) to perform traffic object detection, drivable area segmentation, and lane detection simultaneously. It is composed of one encoder for feature extraction and three decoders to handle the specific tasks. Our model performs extremely well on the challenging BDD100K dataset, achieving state-of-the-art on all three tasks in terms of accuracy and speed. Besides, we verify the effectiveness of our multi-task learning model for joint training via ablative studies. To our best knowledge, this is the first work that can process these three visual perception tasks simultaneously in real-time on an embedded device Jetson TX2(23 FPS), and maintain excellent accuracy. To facilitate further research, the source codes and pre-trained models are released at <https://github.com/hustvl/YOLOP>.

Springer

ẨN BÓT ^

☆ Lưu Trích dẫn Trích dẫn 597 bài viết Bài viết có liên quan Tất cả 8 phiên bản

Các bài báo nền tảng(3)




Fig. 2 The architecture of YOLOP. YOLOP shares one encoder and combines three decoders to solve different tasks. The encoder consists of a backbone and a neck.

YOLOP sử dụng **một encoder** chung để trích xuất đặc trưng từ ảnh.

Sau đó đặc trưng được chia cho ba nhánh xử lý gồm phát hiện **phương tiện**, phân đoạn vùng có thể di chuyển và phân đoạn vạch làn. Kiến trúc **multi-task** này giúp giảm việc sử dụng nhiều mô hình riêng biệt và cho phép xử lý cả ba nhiệm vụ đồng thời.

Yolop: You only look once for panoptic driving perception

D Wu, MW Liao, WT Zhang, XG Wang, X Bai, WQ Cheng, WY Liu

Machine Intelligence Research, 2022 • Springer

Abstract

A panoptic driving perception system is an essential part of autonomous driving. A high-precision and real-time perception system can assist the vehicle in making reasonable decisions while driving. We present a panoptic driving perception network (you only look once for panoptic (YOLOP)) to perform traffic object detection, drivable area segmentation, and lane detection simultaneously. It is composed of one encoder for feature extraction and three decoders to handle the specific tasks. Our model performs extremely well on the challenging BDD100K dataset, achieving state-of-the-art on all three tasks in terms of accuracy and speed. Besides, we verify the effectiveness of our multi-task learning model for joint training via ablative studies. To our best knowledge, this is the first work that can process these three visual perception tasks simultaneously in real-time on an embedded device Jetson TX2(23 FPS), and maintain excellent accuracy. To facilitate further research, the source codes and pre-trained models are released at <https://github.com/hustvl/YOLOP>.

Springer

ẨN BÓT ^

☆ Lưu 77 Trích dẫn Trích dẫn 597 bài viết Bài viết có liên quan Tất cả 8 phiên bản

Khảo sát các bài báo gần hướng (1)

Vấn đề giải quyết


A-YOLOM tập trung vào **ba yêu cầu** quan trọng của **hệ thống lái tự động**:

- + Độ chính xác cao (high precision)
- + Mô hình nhẹ (lightweight)
- + Xử lý thời gian thực (real-time)

Output thực tế

Object Detection, Drivable Area Segmentation, Lane Line Segmentation

YOLOP



A-YOLOM(n)



A-YOLOM(s)



JOURNAL OF LATEX CLASS FILES, VOL. 14, NO. 8, AUGUST 2021

You Only Look at Once for Real-Time and Generic Multi-Task

Jiayuan Wang, *Graduate Student Member, IEEE*, Q. M. Jonathan Wu, *Senior Member, IEEE*, and Ning Zhang, *Senior Member, IEEE*

Abstract—High precision, lightweight, and real-time responsiveness are three essential requirements for implementing autonomous driving. In this study, we incorporate A-YOLOM, an adaptive, real-time, and lightweight multi-task model designed to concurrently address object detection, drivable area segmentation, and lane line segmentation tasks. Specifically, we develop an end-to-end multi-task model with a unified and streamlined segmentation structure. We introduce a learnable parameter that adaptively concatenates features between necks and backbone in segmentation tasks, using the same loss function for all segmentation tasks. This eliminates the need for customizations and enhances the model's generalization capabilities. We also introduce a segmentation head composed only of a series of convolutional layers, which reduces the number of parameters and inference time. We achieve competitive results on the BDD100k dataset, particularly in visualization outcomes. The performance results show a mAP50 of 81.1% for object detection, a mIoU of 91.0% for drivable area segmentation, and an IoU of 28.8% for lane line segmentation. Additionally, we introduce real-world scenarios to evaluate our model's performance in a real scene, which significantly outperforms competitors. This demonstrates that our model not only exhibits competitive performance but is also more flexible and faster than existing multi-task models. The source codes and pre-trained models are released at <https://github.com/JiayuanWang-JW/YOLOv8-multi-task>

Index Terms—Multi-task learning, panoptic driving perception, object detection, drivable area segmentation, lane line segmentation




Fig. 1: Multi-task in autonomous driving: object detection, drivable area segmentation and lane line segmentation

model becomes a formidable solution. Additionally, high precision, real-time and lightweight are essential in autonomous driving tasks. In emergencies, ADS must fast and accurately decide to avoid potential collisions or safely around obstacles. Accurately and fast estimating the drivable area and lane lines is important for effective route planning. In fact, maintaining a frame rate exceeding 30 frames per second (FPS) is imperative for ADS [4], [5]. Given the limited computational

0.01641v4 [cs.CV] 24 Apr 2024

Khảo sát các bài báo gần hướng (1)

Backbone – trích xuất đặc trưng chung

Nhiệm vụ + nhận ảnh đầu vào

- + trích xuất **feature** ở nhiều mức;
- + các **feature** này được dùng chung cho cả:

Object Detection, Drivable Area Segmentation, Lane Line Segmentation.

Backbone dùng chung để trích xuất đặc trưng đa mức từ ảnh đầu vào, giúp giảm việc tính toán lặp lại giữa các nhiệm vụ.

Detect Neck

lấy feature từ nhiều mức của Backbone, sau đó dùng:

- + **US** – Upsampling: tăng kích thước feature map;
- + **C** – Concatenate: nối các feature từ nhiều tầng;
- + **C2f**: xử lý và tinh chỉnh feature;
- + **CBS**: Convolution + Batch Normalization + SiLU.

Feature nông (shallow feature) = đặc trưng lấy ở những tầng gần ảnh đầu vào. Nó còn giữ nhiều thông tin về vị trí, cạnh, đường viền, chi tiết nhỏ. (VD cạnh xe nằm ?, kích thước ?)

Feature sâu (deep feature) = đặc trưng lấy ở những tầng sâu hơn của backbone. Nó đã qua nhiều lớp xử lý nên hiểu tốt hơn “đây là xe”, “đây là đường”, “đây là lane”, nhưng thông tin vị trí chi tiết có thể bị giảm đi. (VD là xe?)




Fig. 2: A-YOLOM structure

Detect Head

Bbox : vị trí của phương tiện.

Cls : loại đối tượng

Khảo sát các bài báo gần hướng (1)

Segment Neck x N

× N có nghĩa là kiến trúc segmentation có thể được **lặp lại cho nhiều segmentation task**.

Trong bài toán hiện tại:
 một branch → Drivable Area
 một branch → Lane Line

A-YOLOM có tính **generic multi-task**: nếu sau này muốn thêm một segmentation task khác, về nguyên tắc có thể bổ sung một branch tương tự.

AC – Adaptive Concatenate

Phần **quan trọng** nhất để **phân biệt** A-YOLOM

Mục tiêu:

- + giảm việc thiết kế thủ công
- + tăng tính tổng quát;
- + cho phép cùng một kiến trúc segmentation áp dụng cho nhiều task khác nhau.

Adaptive Concatenate tự động lựa chọn/kết hợp đặc trưng phù hợp từ **Backbone** cho từng nhiệm vụ segmentation.




Fig. 2: A-YOLOM structure

Segment Head

Để giảm tài nguyên

Output :

- + **Mask 1** Drivable Area Mask
- + **Mask 2** Lane Line Mask

*Thank you teacher and everyone for listening to the presentation. Have a **good** day*

